

Тренировочное задание по теме
„Составления отчета по проделанной работе“.

Целевая аудитория : заказчик исследования.

Основная мысль отчёта: Отображение существенных критических мест в данной задаче (несбалансированность предсказываемых классов в предоставленном наборе данных).
Выдвижение альтернативных задач на основе существующих данных, которые можно решить.

Способ коммуникации: отчёт для самостоятельного изучения с последующим обсуждением.

Отчет по решению задачи

“Проведение моделирования классификации вин”

Содержение

- Постановка задачи
- Описание данных и выявление проблем
- Подготовка данных для моделирования
- Моделирование и анализ результатов
- Возможные пути развития

Постановка задачи.

Для отбора ассортимента продаваемых вин в сети магазинов ААА данный момент для этого используется экспертная оценка.

Сложность данного метода заключается в следующем:

1. Требуется физически предоставить образцы вин эксперту для вынесения оценки, на проведение экспертизы и составления отчёта требуется время.
2. Категоризация сильно зависит от эксперта и в случае вынужденной замены человека, выполняющего эту работу, возможно смещение оценки в ту или иную сторону.

Постановка задачи.

Была выдвинута гипотеза:

- С помощью алгоритмов машинного обучения можно автоматизировать процесс категоризации новых образцов вин, основываясь на данных проведенных ранее экспертиз.

При качестве работы модели по критерию **accuracy** равному **80%** и выше можно **сократить траты** на экспертную оценку на 40000 руб/мес и **ускорить процесс** категоризации вин на 25мин/образец.

$$accuracy = \frac{\text{число верных предсказаний классов}}{\text{общее число предсказаний}} * 100\%$$


Описане данных и выявление проблем

Набор данных представляет из себя таблицу с **количеством образцов 6497**. Каждый образец охарактеризован 12 свойствами (параметрами). Последнее свойство в таблице (качество образца) требуется предсказать.

тип	фиксированная кислотность	летучая кислотность	лимонная кислота	остаточный сахар	хлориды	свободный диоксид серы	общий диоксид серы	плотность	pH	сульфаты	алкоголь	качество
white	7.0	0.27	0.36	20.7	0.045	45.0	170.0	1.0010	3.00	0.45	8.8	6
white	6.3	0.30	0.34	1.6	0.049	14.0	132.0	0.9940	3.30	0.49	9.5	6
white	8.1	0.28	0.40	6.9	0.050	30.0	97.0	0.9951	3.26	0.44	10.1	6

Описане данных и выявление проблем

Существенным недостатком в данном наборе данных является **сильная несбалансированность по классам.**




Описане данных и выявление проблем

Другие особенности:

- **10** образцов в предоставленном наборе обладают пропусками по одному из параметров в данных.
- **102** образца (около 2.5%) значительно отличаются по одному из параметров от остальных в предоставленном наборе данных. Наличие таких данных может быть как ошибкой при занесении данных об образцах, так и уникальностью данных образцов. Пример подобных образцов с указанием параметра со значительным отличием приведен ниже.

	тип	фиксированная кислотность	летучая кислотность	лимонная кислота	остаточный сахар	хлориды	свободный диоксид серы	общий диоксид серы	плотность	pH	сульфаты	алкоголь	качество
0	white	7	0.27	0.36	20.7	0.045	45	170	1.001	3	0.45	8.8	6
7	white	7	0.27	0.36	20.7	0.045	45	170	1.001	3	0.45	8.8	6
182	white	6.8	0.28	0.4	22	0.048	48	167	1.001	2.93	0.5	8.7	5
191	white	6.8	0.28	0.4	22	0.048	48	167	1.001	2.93	0.5	8.7	5
207	white	10.2	0.44	0.88	6.2	0.049	20	124	0.9968	2.99	0.51	9.9	4
325	white	7.5	0.27	0.31	5.8	0.057	131	313	0.9946	3.18	0.59	10.5	5
444	white	6.9	0.24	0.36	20.8	0.031	40	139	0.9975	3.2	0.33	11	6
745	white	7.4	0.2	1.66	2.1	0.022	34	113	0.99165	3.26	0.55	12.2	6
946	white	8.2	0.345	1	18.2	0.047	55	205	0.99965	2.96	0.43	9.6	5
1051	white	6.9	0.21	0.81	1.1	0.137	52	123	0.9932	3.03	0.39	9.2	6

Описане данных и выявление проблем



Другие особенности:

- Наблюдается взаимосвязь между отдельными параметрами в предоставленном наборе данных. В качестве меры взаимосвязи была выбрана корреляция. Так **корреляция между параметрами 'алкоголь' и 'плотность' равна -0.69** (чем выше содержание алкоголя, тем ниже плотность) . Высокая корреляция между параметрами образцов может привести к тому, что обученная модель может получиться неустойчивой: **при незначительном изменении одного из параметров** поведение модели изменится гораздо сильнее требуемого и **предсказание класса качества вина будет ошибочным.**

Подготовка данных для моделирования

Меры по обработке входных данных:

1. Принято решение об **исключении** из набора данных **образцов с пропусками и со значительными отличиями** в параметрах. Предполагается, что это приведет к более устойчивой работе модели по основному набору.

2. Для исключения взаимосвязей между параметрами образцов предлагается произвести **создание новых факторов на базе параметров с высокой корреляцией** в виде комбинаций произведений этих параметров. При этом использованные для создания новых факторов параметры изымаются из описания образцов.

Таким образом предлагается **уменьшить взаимную корреляцию признаков**, используемых при создании модели.

Подготовка данных для моделирования

Таким образом были сформированы новые 4 фактора:

*Фактор 1 = фиксированная кислотность * плотность*

*Фактор 2 = летучая кислотность * лимонная кислота * хлориды * общий диоксид серы*

*Фактор 3 = остаточный сахар * свободный диоксид серы * общий диоксид серы*

*Фактор 4 = плотность * алкоголь*

Используемые для создания новых факторов признаки не будут использоваться при создании модели классификации.

Моделирование и анализ результатов

Полученный набор данных был использован для обучения многоклассового классификатора. Качество работы по критерию **accuracy** составило **42%** на тестовой выборке, что существенно ниже требуемого уровня.

Моделирование и анализ результатов

	Класс 3	Класс 4	Класс 5	Класс 6	Класс 7	Класс 8	Класс 9
Предсказанный класс 3	1	4	3	1	3	0	0
Предсказанный класс 4	0	23	27	16	8	3	0
Предсказанный класс 5	13	90	348	144	25	5	0
Предсказанный класс 6	10	71	214	299	160	45	0
Предсказанный класс 7	0	16	24	105	128	58	1
Предсказанный класс 8	0	4	0	12	24	20	1
Предсказанный класс 9	0	0	0	1	1	1	0

Таблица предсказаний по классам

Здесь:


колонки - классы вина, выставленные экспертом,

строки - предсказанный математической моделью класс вина.

На диагонали матрицы находится верное количество угаданных образцов (предсказание модели совпадает с классом, выставленный экспертом)

Заметно, что модель стремится ставить оценки ближе к среднему значению качества по всему набору данных.

Моделирование и анализ результатов



Следует отметить, модель в большинстве случаев ошибалась **не более чем 1 класс** вверх или вниз относительно экспертной оценки.

Если исключить эти ошибки (не более чем на 1 класс) из общего числа, **качество прогнозирования существенно увеличивается.**

Возможные пути развития

Так как математическая модель не смогла показать требуемое качество работы, возможны следующие варианты дальнейшей работы:

1. **Отказ** от использования алгоритмов машинного обучения в связи с недостижением требуемого качества.
- 2. Остановка исследования для **увеличения количества тренировочных данных**, используемых при машинном обучении. Классификация производится с помощью экспертной оценки, новые отчеты добавляются к тренировочным данным для машинного обучения
- 3. Огрубление классификации путём **уменьшения количества классов** (использовать не 9, а 3 класса) .
4. Исследование использования **других моделей** классификации.
- 5. Запуск модели в существующем виде для сравнения количества проданного вина при экспертной оценке и с помощью алгоритмов машинного обучения (**A/B тестирование**)