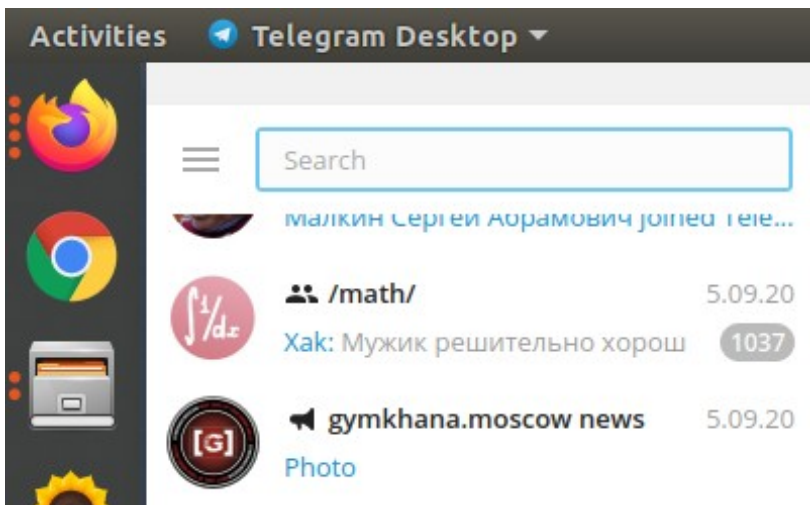


Исследование методов парсинга в многосторонних диалогах.

Смольников Виталий
Москва
2020

Постановка задачи

Высока вероятность среди всего информационного шума пропустить важные или информативные сообщения



В качестве возможного решения задачи разбора многостороннего диалога была выдвинута гипотеза: **автоматический синтез взаимосвязей между отдельными фразами может сильно облегчить анализ многостороннего диалога.**

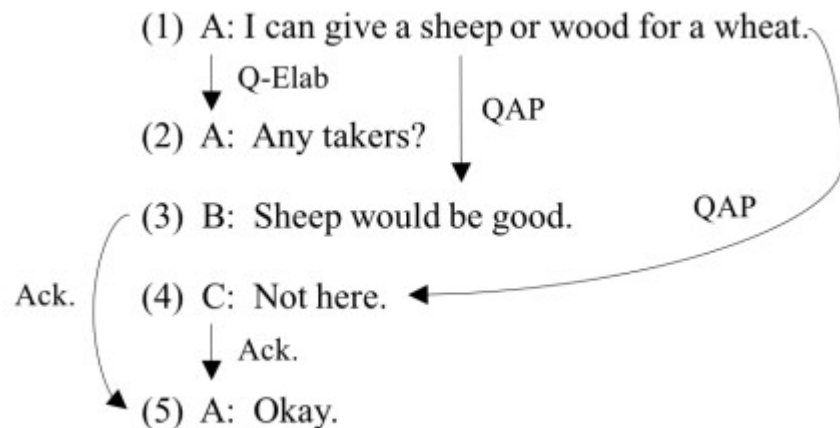
Метрики

$$Precision_{Micro} = \frac{TP_{summ}}{TP_{summ} + FP_{summ}}$$

$$Recall_{Micro} = \frac{TP_{summ}}{TP_{summ} + FN_{summ}}$$

$$F1_{Micro} = \frac{2 * Precision_{Micro} * Recall_{Micro}}{Precision_{Micro} + Recall_{Micro}}$$

Постановка задачи




Пример многостороннего диалога с его структурой дискурса из корпуса STAC (Asher и др., 2016), где «Q-Elab» - это сокращение от «Вопрос-разработка», «QAP» для «пара вопрос-ответ». и «ACK.» для «Подтверждение».

Анализ

- Исследование предыдущих решений.

234	18:55:02:745	gotwood4sheep	anyone got wheat for a sheep?
235	18:55:10:047	inca	sorry, not me
236	18:55:18:787	CheshireCatGrin	nope. you seem to have lots of sheep!
237	18:55:23:428	gotwood4sheep	yup baaa
238	18:55:32:308	dmm	i think i'd rather hang on to my wheat i'm afraid
239	18:55:47:845	gotwood4sheep	kk I'll take my chances then...



Пример направленного ациклического графа (DAG).

Анализ

- Исследование предыдущих решений.

Модель	F1 связь	F1 связь и тип
ILP	67.1	51.6
DSM	73.2	55.7

<https://www.aclweb.org/anthology/D15-1109.pdf>

<https://arxiv.org/pdf/1812.00176.pdf>

Анализ

- STAC Corpus

	Всего	Тренировочная выборка	Тестовая выборка
Диалогов	1091	968	123
Кол-во EDU	10677	9545	1132
Кол-во связей	11348	1058	1190

Два недостатка :

- язык — английский
- много избыточной информации о состоянии игры.

Анализ данных

- EN – RU
- библиотека googletrans

- Избыточность информации

- ```
{ "id": "s1-league3-game3",
```
- ```
  "edus":
```
- ```
 [{"speaker": "nareik15", "text": "эээ ... как принять сделку?"},
```
- ```
      {"speaker": "inca", "text": "у тебя есть пшеница?"},
```
- ```
 {"speaker": "yiin", "text": "ара, я тоже не уверен"},
```
- ```
      {"speaker": "nareik15", "text": "да, могу торговать"},
```
- ```
 {"speaker": "nareik15", "text": "но может видеть только кнопку \"отклонить\""}],
```
- ```
    "relations":
```
- ```
 [{"type": "Contrast", "x": 3, "y": 4},
```
- ```
        {"type": "Q-Elab", "x": 0, "y": 1},
```
- ```
 {"type": "Parallel", "x": 0, "y": 2},
```
- ```
        {"type": "Question-answer_pair", "x": 1, "y": 3}]]
```

Обзор модели

Для текущего EDU u_i модель предсказывает связь зависимостей, оценивая распределение вероятностей следующим образом:

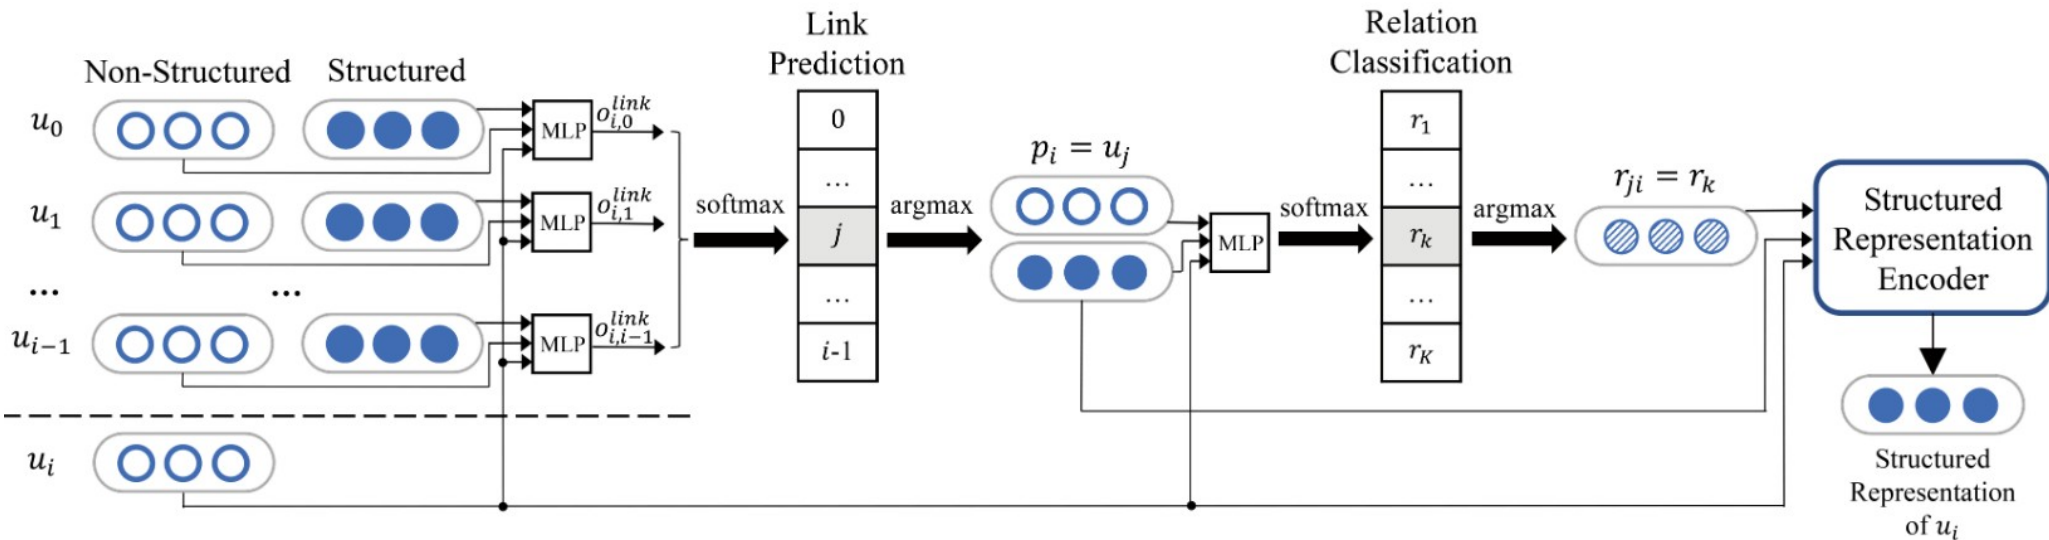
$$\mathcal{P}(u_j | u_i, \mathcal{F}, 0 \leq j \leq i - 1)$$

где $\mathcal{F} = \{(u_l, u_k, r_{lk}) \mid 0 \leq l \leq k \leq i - 1\}$ - это набор отношений зависимостей, которые уже предсказаны перед текущим шагом i . В данной модели это так называемое *предсказание ссылки*. Аналогичным образом модель предсказывает тип отношения для предсказанной ссылки $u_j \rightarrow u_i$ ($j < i$) со следующим распределением:

$$\mathcal{P}(r_{ji} | u_j \rightarrow u_i, \mathcal{F}_i)$$

где $r_{ji} \in \{r_1, r_2, \dots, r_K\}$, r_k ($1 \leq k \leq K$) - тип отношения, а K - количество типов отношений. Это так называемая *классификация отношений*.


Обзор модели




Для текущего EDU u_i прогнозирование связи оценивает распределение по предыдущим EDU, классификация отношений оценивает распределение по типам связей, а структурированный кодер обновляет структурированное (Structured) представление u_i , используя представления u_i и p_i и эмбединг прогнозируемого отношения r_{ji} .

Обзор модели

Локальные представления создаются с помощью Bi-GRU



Общая структура Bi-GRU



Ячейка GRU

Параметры модели (итоговой)

- векторы слов инициализируются 300-мерными GloVe векторами
- размер словаря 1000 слов
- Максимальное расстояние между связуемыми фразами = 20
- Размер эмбединга отношений = 100
- Количество скрытых юнитов = 256
- dropout= 0.5

Результаты


- Результаты работы различных вариантов.

Модель	F1, %
Deep Sequential , en, GloVe	69.7
Deep Sequential , ru, GloVe	70.4
Deep Sequential , ru, FastText	69
Dummy*	54


Dummy - простая модель – дающая предсказание связи к ближайшему соседу

Результаты

Зависимость F1 от количества фраз в диалоге

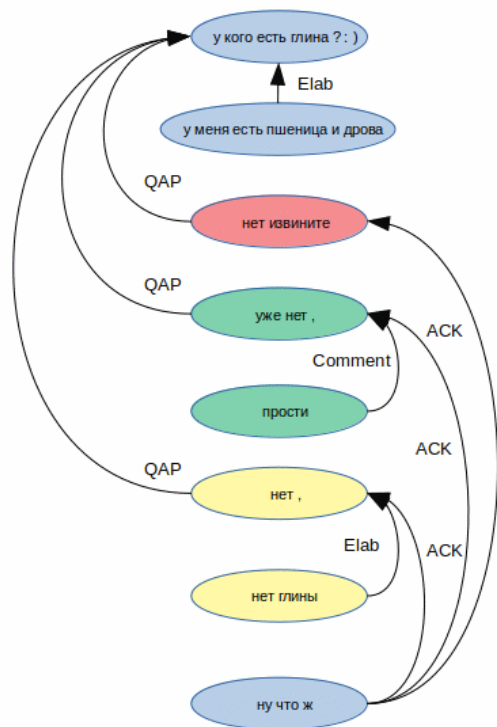


Зависимость F1 от количества эпох в обучении

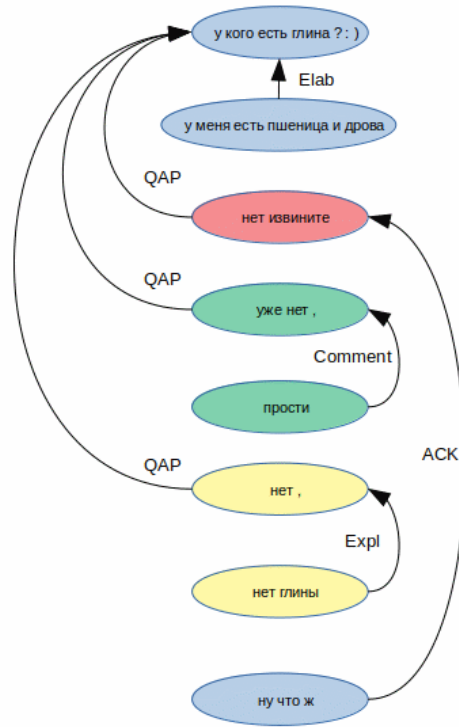


Результаты. Пример

Размечено в датасете



Передсказано в модели



Типы связей:
Elaboration - проработка,
QAP – пара-вопрос-ответ,
ACK- подтверждение,
Comment – комментарий,
Explanation - объяснение

Итоги и планы на развитие

- Итоги
- Перенос модели на датасет диалогами на русском языке дает схожие результаты.
- Заметно, что качество работы модели на длинных диалогах заметно падает.
- Главная проблема на данном этапе - отсутствие большого размеченного датасета на русском языке.
- План развития.
 - Провести разметку существующих датасетов с помощью данного алгоритма*.
 - Перевод модели на TF 2.
 - Использование направленного ациклического графа.
 - Обучение модели на большом датасете.
 - Исследование возможности использования Multilingual Universal Sentence Encoder for Semantic Retrieval**

* <https://www.kaggle.com/dolfik/russian-telegram-chats-history>

**<https://arxiv.org/pdf/1907.04307.pdf>